

Sistema de Busca e Classificação de Animais de Estimação

Trabalho 3 — Processamento de Imagens

Ayrton da Costa Ganem Filho - 14560190

28 de maio de 2026

1 Introdução

Este trabalho apresenta um sistema de busca e classificação de animais de estimação baseado em descritores de imagens clássicos. A base de dados contém 42 classes de pets (367 imagens, resolução 256×256) coletadas por estudantes da disciplina.

Os objetivos principais são:

1. **Classificação:** dado um conjunto de imagens, treinar um classificador para identificar o pet correto.
2. **Busca (Retrieval):** dada uma imagem de consulta, retornar um ranking das imagens mais similares na base.
3. **Bag of Visual Words (BoVW):** construir representações baseadas em dicionário visual e visualizar a distribuição dos descritores.

Foram selecionados 6 descritores de imagens (5 vistos em aula + 1 inédito) para explorar diferentes semânticas: cor, textura, forma e padrões locais.

2 Metodologia

2.1 Base de Dados

A base contém 42 classes de pets com número variável de imagens por classe (de 1 a 20). Para a tarefa de classificação, classes com menos de 3 imagens foram excluídas, resultando em 38 classes válidas com 362 imagens. As imagens foram padronizadas para 256×256 pixels.

2.2 Descritores de Imagens

2.2.1 1. GCH — Global Color Histogram

Semântica: Captura a distribuição global de cores da imagem.

Justificativa: O histograma de cores é o descritor mais fundamental para diferenciar pets com pelagens de cores distintas. Pets com pelagem escura vs. clara, ou com manchas coloridas, devem se separar bem com este descritor.

Implementação: Conversão para espaço HSV, quantização em $16 \times 4 \times 4 = 256$ bins, normalização L1.

2.2.2 2. LBP — Local Binary Patterns

Semântica: Captura padrões de textura local.

Justificativa: A textura da pelagem é uma característica discriminante importante. Pets com pelo liso vs. crespo, curto vs. longo, devem apresentar padrões LBP distintos.

Implementação: LBP uniforme com $P = 24$ vizinhos e raio $R = 3$, resultando em histograma de 26 bins.

2.2.3 3. Haralick — Features GLCM

Semântica: Captura relações estatísticas de textura via matrizes de co-ocorrência.

Justificativa: Complementa o LBP com medidas estatísticas (contraste, homogeneidade, energia, correlação) que descrevem propriedades globais de textura. Útil para diferenciar fundos texturizados e tipos de pelagem.

Implementação: GLCM com distâncias (1, 2, 3) e 4 ângulos, 64 níveis de quantização. Extração de 6 propriedades (média e desvio), totalizando 12 features.

2.2.4 4. HOG — Histogram of Oriented Gradients

Semântica: Captura informações de forma e bordas.

Justificativa: A silhueta e a forma do animal são informações importantes. HOG deve capturar diferenças entre espécies (gatos vs. cães) e poses distintas do mesmo animal.

Implementação: 9 orientações, células de 16×16 pixels, blocos 2×2 , normalização L2-Hys. Imagem redimensionada para 128×128 .

2.2.5 5. Color Correlogram

Semântica: Captura a distribuição espacial de cores — mede a probabilidade de encontrar a mesma cor a uma certa distância.

Justificativa: Diferente do GCH, o correlograma preserva informação espacial. Pets com manchas concentradas vs. distribuídas devem apresentar correlogramas distintos.

Implementação: Autocorrelograma no canal H (HSV), distâncias (1, 3, 5), 16 níveis de quantização. Vetor de $16 \times 3 = 48$ dimensões.

2.2.6 6. Gabor Filters (Não Visto em Aula)

Semântica: Captura textura em diferentes frequências espaciais e orientações específicas.

Justificativa: Os filtros de Gabor modelam a resposta de células visuais simples do córtex humano. Eles complementam LBP e Haralick ao capturar texturas em múltiplas escalas e direções simultaneamente, sendo particularmente eficazes para diferenciar padrões de pelagem com orientação preferencial (listras, manchas regulares).

Implementação: Banco de filtros com 5 frequências (0.05, 0.1, 0.2, 0.3, 0.4) e 8 orientações. Para cada filtro, extrai-se média e desvio padrão da resposta, totalizando $2 \times 5 \times 8 = 80$ features.

2.3 Pipeline de Classificação

1. **Filtragem:** Classes com menos de 3 imagens são excluídas (38 classes válidas, 362 imagens).
2. **Divisão:** Split estratificado em treino (80%), validação (10%) e teste (10%).
3. **Normalização:** StandardScaler (média 0, desvio 1) ajustado no treino.
4. **Classificador:** SVM (Support Vector Machine) com seleção de kernel (linear vs. RBF) via validação.
5. **Avaliação:** Acurácia, F1-score ponderado, e matrizes de confusão no conjunto de teste.

2.4 Pipeline de Busca

2.4.1 Busca Par a Par

Para cada imagem query, calcula-se a distância euclidiana no espaço de features (normalizado) contra todas as demais imagens. O ranking é construído em ordem crescente de distância.

Métricas: Precision@1, Precision@5, Precision@10, e Mean Average Precision (mAP).

2.4.2 Bag of Visual Words (BoVW)

1. Extração de descritores locais (ORB) de todas as imagens (140.602 descritores locais extraídos).
2. Criação de dicionário visual de 200 visual words via K-Means.
3. Representação de cada imagem como histograma de visual words (normalizado L1).
4. Busca por distância euclidiana entre histogramas BoVW.

2.5 Visualização BoVW

Os histogramas BoVW são projetados em 2D usando:

- **t-SNE:** Preserva estrutura local, boa para visualizar clusters.
- **UMAP:** Preserva estrutura local e global, geralmente mais rápido.

3 Resultados

3.1 Resultados de Classificação

A Tabela 1 apresenta os resultados de classificação para cada descritor e combinações. O split resultou em 289 imagens de treino, 36 de validação e 37 de teste.

Tabela 1: Resultados de classificação (SVM) por descritor e combinações.

Descritor(es)	Dim.	Val Acc	Test Acc	Test F1
GCH	256	36,11%	32,43%	0,2985
LBP	26	16,67%	18,92%	0,1766
Haralick	12	25,00%	29,73%	0,2561
HOG	1764	22,22%	18,92%	0,1289
Correlogram	48	25,00%	16,22%	0,1399
Gabor	80	27,78%	43,24%	0,4028
GCH + LBP	282	33,33%	37,84%	0,3495
GCH + Haralick	268	38,89%	40,54%	0,3532
GCH + LBP + HOG	2046	36,11%	29,73%	0,2180
GCH + LBP + Haralick + Gabor	374	38,89%	43,24%	0,3668
Todos	2186	47,22%	40,54%	0,3198

Análise dos resultados de classificação:

- O **Gabor** (não visto em aula) obteve o melhor desempenho individual, com 43,24% de acurácia no teste e F1 de 0,40. Isso indica que a resposta em múltiplas frequências e orientações captura informações altamente discriminantes sobre a textura dos pets.
- O **GCH** foi o segundo melhor descritor individual (32,43%), confirmando que a cor é uma característica importante mas insuficiente sozinha.
- O **HOG** e o **LBP** tiveram desempenho baixo isoladamente (18,92%), indicando que forma e textura local sozinhas não são suficientes para este problema com muitas classes.
- A combinação **GCH + LBP + Haralick + Gabor** igualou o Gabor individual (43,24%), mostrando que descritores complementares contribuem mas a adição do HOG (alta dimensionalidade) prejudica o desempenho.
- A combinação de **todos os descritores** obteve a melhor acurácia de validação (47,22%), mas no teste caiu para 40,54%, sugerindo overfitting possivelmente causado pela alta dimensionalidade (2186 features para apenas 289 amostras de treino).

3.1.1 Matrizes de Confusão

As Figuras 1 e 2 mostram as matrizes de confusão para os descritores com melhor desempenho.




Figura 1: Matriz de confusão — Gabor (melhor descritor individual, Acc=43,24%).




Figura 2: Matriz de confusão — Todos os descritores combinados (Acc=40,54%).




Figura 3: Matriz de confusão — GCH (segundo melhor individual, Acc=32,43%).

3.2 Resultados de Busca

A Tabela 2 apresenta os resultados de busca para cada descritor e combinações.

Tabela 2: Resultados de busca (distância euclidiana) por descritor e combinações.

Descritor(es)	Dim.	mAP	P@1	P@5	P@10
GCH	256	0,0966	0,2289	0,1281	0,0932
LBP	26	0,0814	0,1199	0,0888	0,0757
Haralick	12	0,0825	0,1526	0,0954	0,0796
HOG	1764	0,0744	0,1499	0,0790	0,0635
Correlogram	48	0,0912	0,1826	0,1117	0,0861
Gabor	80	0,0994	0,2044	0,1253	0,0995
GCH + LBP	282	0,1077	0,2589	0,1368	0,1044
GCH + Haralick	268	0,1055	0,2561	0,1422	0,1027
GCH + LBP + HOG	2046	0,0866	0,1880	0,0926	0,0717
Todos	2186	0,0990	0,2234	0,1161	0,0894

Análise dos resultados de busca:

- A combinação **GCH + LBP** obteve o melhor mAP (0,1077) e P@1 (25,89%), mostrando que cor + textura local é a combinação mais eficaz para busca.
- **GCH + Haralick** ficou muito próximo, com o melhor P@5 (0,1422), indicando que textura estatística (Haralick) contribui de forma similar ao LBP quando combinada com cor.
- O **HOG** teve o pior desempenho individual (mAP=0,0744), confirmando que a informação de forma/borda sozinha não é discriminante suficiente neste contexto.

- Curiosamente, a combinação de **todos** os descritores ($mAP=0,0990$) foi inferior a GCH+LBP, sugerindo que a alta dimensionalidade prejudica a distância euclidiana (“maldição da dimensionalidade”).

3.2.1 Exemplos de Busca

A Figura 4 mostra exemplos de busca usando a combinação GCH+LBP. As imagens com borda verde indicam resultados corretos (mesmo pet), enquanto bordas vermelhas indicam resultados incorretos.



Figura 4: Exemplo de busca com GCH+LBP. Verde = mesmo pet, Vermelho = pet diferente.

3.3 Resultados BoVW

3.3.1 Métricas de Busca BoVW

O método Bag of Visual Words foi implementado usando descritores locais ORB, com um dicionário visual de 200 visual words construído via K-Means. Os resultados são apresentados na Tabela 3.

Tabela 3: Resultados de busca com Bag of Visual Words (ORB + K-Means, K=200).

Método	mAP	P@1	P@5
BoVW (ORB, 200 visual words)	0,0658	0,0954	0,0621
<i>Comparação:</i> Melhor descritor global (GCH+LBP)	0,1077	0,2589	0,1368

Análise: O BoVW com ORB apresentou desempenho inferior aos descritores globais. Isso pode ser explicado pelo fato de que o ORB, sendo um descritor binário otimizado para velocidade, não captura nuances de cor e textura tão bem quanto descritores especializados como GCH e LBP. Além disso, com 42 classes heterogêneas (diferentes espécies, poses e ambientes), as visual words podem não ter formado agrupamentos semânticos bem definidos.

3.3.2 Visualizações t-SNE e UMAP

As Figuras 5 e 6 mostram as projeções t-SNE e UMAP dos histogramas BoVW.




Figura 5: Projeção t-SNE dos histogramas Bag of Visual Words. Cada cor representa um pet diferente.




Figura 6: Projeção UMAP dos histogramas Bag of Visual Words.

4 Análise e Hipóteses

4.1 GCH — Global Color Histogram

Hipótese inicial: O histograma de cores deveria funcionar bem para diferenciar pets com pelagens de cores muito distintas, mas falhar para pets de mesma cor.

Resultado: Com acurácia de 32,43% na classificação e mAP de 0,0966 na busca, o GCH foi o segundo melhor descritor individual. Isso confirma que a cor é uma característica discriminante importante nesta base, onde muitos pets possuem pelagens de cores diferentes. Na busca, o P@1 de 22,89% indica que em quase 1 a cada 4 consultas, o vizinho mais próximo é do mesmo pet — um resultado razoável para um descritor tão simples.

4.2 LBP — Local Binary Patterns

Hipótese inicial: O LBP deveria capturar diferenças de textura da pelagem e melhorar quando combinado com cor.

Resultado: Isoladamente, o LBP teve desempenho baixo (18,92% classificação, mAP 0,0814 busca), pois com apenas 26 dimensões ele é muito compacto e as variações de iluminação/pose degradam a discriminação. Contudo, **combinado com GCH**, gerou os melhores resultados de busca (mAP 0,1077), confirmando a hipótese de complementaridade cor-textura.

4.3 Haralick (GLCM)

Hipótese inicial: Com 12 dimensões, seria mais útil como complemento.

Resultado: Surpreendentemente, o Haralick sozinho (29,73%) superou o LBP, o HOG e o Correlograma na classificação. Isso sugere que as medidas estatísticas globais de textura (contraste, energia, homogeneidade) capturam informações discriminantes importantes. Na busca, GCH+Haralick obteve o melhor P@5 (0,1422), validando sua utilidade como complemento.

4.4 HOG — Histogram of Oriented Gradients

Hipótese inicial: O HOG deveria capturar silhuetas e formas, mas sofreria com a alta dimensionalidade.

Resultado: O HOG teve o pior desempenho individual na busca (mAP 0,0744) e empatou com LBP na classificação (18,92%). A hipótese da “maldição da dimensionalidade” se confirmou: com 1764 features para uma base pequena (367 imagens), o HOG dilui a informação relevante. Além disso, a grande variação de poses dos pets torna a informação de forma pouco confiável para identificação individual.

4.5 Color Correlogram

Hipótese inicial: Deveria superar o GCH ao considerar informação espacial.

Resultado: O Correlograma (16,22% classificação, mAP 0,0912 busca) ficou abaixo do GCH em ambas as tarefas. Isso pode ser explicado pela implementação usando apenas o canal H do HSV (informação de matiz), enquanto o GCH usa os três canais HSV. A informação espacial adicionada não compensou a perda de informação de saturação e brilho.

4.6 Gabor Filters

Hipótese inicial: Deveria complementar LBP e Haralick com textura multi-escala e multi-orientação.

Resultado: O Gabor foi o **melhor descritor individual** tanto na classificação (43,24%) quanto na busca (mAP 0,0994). Com 80 dimensões (boa relação custo-benefício), ele captura informações de textura ricas que os outros descritores não conseguem representar. Isso valida a escolha deste descritor como complemento ao currículo da disciplina.

4.7 Combinações de Descritores

Hipótese inicial: Combinações de diferentes semânticas superariam descritores individuais.

Resultado: Parcialmente confirmado:

- Na busca, **GCH+LBP** e **GCH+Haralick** superaram todos os descritores individuais, confirmando a complementaridade cor+textura.
- Na classificação, a combinação **GCH+LBP+Haralick+Gabor** igualou o melhor individual (Gabor).
- A adição do HOG degradou os resultados em todos os casos (GCH+LBP+HOG pior que GCH+LBP), confirmando que descritores de alta dimensionalidade com informação pouco relevante prejudicam o desempenho.

4.8 Hipóteses sobre a Distribuição BoVW

Na visualização t-SNE (Figura 5):

- Observam-se alguns agrupamentos, mas com alta sobreposição entre classes, consistente com o baixo mAP do BoVW (0,0658).
- Pets com muitas imagens (como hamtaro, kefka, lulu) tendem a formar clusters mais densos e bem definidos.
- Há outliers isolados, provavelmente imagens com pose/fundo muito diferentes das demais do mesmo pet.

Na projeção UMAP (Figura 6):

- A estrutura é mais compacta que o t-SNE, com agrupamentos mais nítidos.
- Algumas classes se separam claramente, indicando que possuem padrões de visual words distintos (possivelmente pets com texturas/ambientes muito específicos).
- A sobreposição geral confirma que o ORB, como descritor binário, não captura suficiente informação discriminante para esta base heterogênea.

5 Conclusão

Este trabalho implementou e avaliou um sistema completo de busca e classificação de animais de estimação usando 6 descritores de imagens clássicos. Os principais achados foram:

- O **Gabor Filters** (não visto em aula) foi o melhor descritor individual, com 43,24% de acurácia na classificação, demonstrando que texturas multi-escala e multi-orientação são altamente informativas para identificação de pets.
- A **combinação de cor e textura** (GCH+LBP ou GCH+Haralick) produziu os melhores resultados de busca, com mAP superior a 0,10.
- Descritores de **alta dimensionalidade** como HOG prejudicaram o desempenho quando a base é pequena, evidenciando a “maldição da dimensionalidade”.
- O **Bag of Visual Words** com ORB teve desempenho inferior aos descritores globais, sugerindo que descritores locais mais informativos (como SIFT) poderiam melhorar os resultados.
- De modo geral, a tarefa de identificar pets individuais (42 classes com poucas imagens) é inerentemente difícil para descritores clássicos, que capturam características visuais genéricas sem entendimento semântico.

Como trabalhos futuros, sugere-se: (i) aumentar a base de dados; (ii) usar descritores locais mais ricos (SIFT/SURF); (iii) explorar redução de dimensionalidade (PCA) antes da classificação; e (iv) comparar com descritores baseados em redes neurais (transfer learning com features de CNNs pré-treinadas).